



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
UNIDADE ACADÊMICA ESPECIALIZADA EM CIÊNCIAS AGRÁRIAS –
ESCOLA AGRÍCOLA DE JUNDIAÍ
CURSO SUPERIOR DE TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE
SISTEMAS

Silvio Gomes bruciaferro

WEB SCRAPING COM PYTHON: COLETA E ESTRUTURAÇÃO DE DADOS

1 RESUMO

Desenvolvi uma aplicação web em Python com **Streamlit** que automatiza a coleta e análise de artigos da Wikipédia, hospedada gratuitamente no **Streamlit Community Cloud**.

Como foi feito:

- **Entrada e URLs:** O usuário digita 5 termos de busca e uma palavra-chave. O código formata esses termos e gera automaticamente os links oficiais da Wikipédia.
- **Raspagem de Dados (Web Scraping):** Implementei dois métodos para coletar o texto dos parágrafos (`<p>`):
 - *Requests + BeautifulSoup*: Coleta síncrona e direta das páginas.
 - *Scrapy*: Extração assíncrona executada em um subprocesso separado (`multiprocessing`) para não travar a aplicação.
- **Limpeza de Texto (NLP):** Removi números de referências (como `[1]`), pontuações e palavras comuns sem valor semântico (*stopwords* em português da biblioteca `nltk`).
- **Visualização no Streamlit:** O dashboard exibe o tempo total da coleta, o número de palavras limpas, a contagem de ocorrências da palavra-chave monitorada e gera uma **Nuvem de Palavras** visual com a biblioteca `wordcloud`.
- **Deploy:** Salvei o código (`app.py`) e as dependências (`requirements.txt`) em um repositório no **GitHub** e conectei diretamente ao **Streamlit Cloud**, que colocou o site no ar com link público HTTPS.